Traduzione automatica neurale fra siciliano, inglese e italiano

Pipeline dei dati e riproduzione delle baseline, da un piccolo Transformer a NLLB addestrato a stadi

Donato Meoli

Human Language Technologies
Università di Pisa

Perché un nuovo traduttore per il siciliano?

- Oggi il siciliano è incluso nei grandi modelli multilingue (NLLB-200), ma il loro siciliano è stato raccolto sul web, da testo non standard: circa un terzo è dialetto, una parte è corso. Il problema è passato dalla *mancanza* di dati alla loro *qualità*.
- Il testo di qualità esiste: dal 1979 *Arba Sicula* pubblica una rivista letteraria bilingue siciliano–inglese.
- Su questa rivista Wdowiak (2021–22) ha costruito il primo sistema di traduzione neurale per il siciliano, allineando le frasi a mano.
- Questo lavoro ricostruisce quel sistema con software ancora mantenuto e una pipeline automatica, e vi applica un modello preaddestrato.

Che cos'è la lingua siciliana?

- La Scuola siciliana, alla corte di Federico II, creò il primo standard letterario d'Italia (XIII secolo) e ispirò Dante.
- Da secoli i dizionari adottano un'ortografia coerente (Pasqualino 1785, Mortillaro, Traina, Nicotra).
- È parlato ogni giorno in Sicilia, Calabria e Puglia, e nelle comunità di emigrati all'estero.
- Morfologicamente ricco, con molte varietà locali e senza un'ortografia ufficiale unica; a scuola non è mai stato insegnato per iscritto.
- Per l'NLP: poco testo parallelo curato, molta flessione, un dominio letterario, cioè un caso *low-resource*.

Indice e contributi

Dalla baseline al nostro sistema:

- dati: dai PDF alle frasi parallele con un sentence encoder;
- baseline: Transformer, sottoparole, la ricetta per pochi dati;
- modello preaddestrato: NLLB-200 adattato con LoRA;
- addestramento a stadi su back-translation selezionate per punteggio;
- risultati su due test set, e la baseline riaddestrata.

Contributi:

- una pipeline automatica dai PDF al testo parallelo (PyMuPDF + LaBSE), tarata sull'allineamento manuale;
- un training set curato, ripulito da ogni sovrapposizione con un test set letterario fisso;
- il tokenizer e la segmentazione orientata alle desinenze riscritti in Python;
- NLLB-200 addestrato a stadi, confrontato con i sistemi pubblicati sul loro test set e nello stesso spazio tokenizzato.

Costruire il corpus parallelo

- Estrazione dai PDF
- Allineamento delle frasi con LaBSE
- Pulizia
- I dataset e l'esclusione del test set

Feng et al., *Language-agnostic BERT Sentence Embedding* (LaBSE).
Thompson & Koehn, *Vecalign*.

Il collo di bottiglia del corpus

- *Arba Sicula* stampa poesia e prosa siciliana su una pagina e la traduzione inglese su quella a fronte.
- Il testo esiste solo come PDF, con due colonne, didascalie, pagine introduttive e, nei numeri più vecchi, rumore da OCR. Wdowiak lo ha allineato a mano con `hunalign` e un dizionario siciliano.
- Obiettivo: recuperare il testo parallelo in automatico, così che il dataset possa crescere senza allineamento manuale.

pagina $2k$ siciliano	**pagina** $2k{+}1$ inglese
poesia / prosa	*traduzione*

Le pagine a fronte suggeriscono già l'accoppiamento; resta da confermare le coppie e da allinearne le frasi.

Estrazione: dal PDF alle pagine accoppiate

1. Lettura dello strato di testo con PyMuPDF (senza il passaggio da pdflatex). I numeri fino ad AS18, e AS21, sono scansioni senza accenti e restano fuori dall'addestramento; da AS19 (1998) i PDF vengono dai file originali.
2. Assegnazione della lingua a ogni pagina in base alla quota di parole funzionali siciliane e inglesi.
3. Confronto di ogni pagina siciliana con la pagina inglese a sinistra e a destra, e accoppiamento greedy per similarità LaBSE, che corregge pagine mal etichettate o invertite.
4. Segmentazione in frasi (`pysbd`), rimozione di testatine, numeri di pagina e frammenti, e ricongiunzione delle parole spezzate a fine riga.

Allineare le frasi: LaBSE e programmazione dinamica

Ogni frase è codificata con LaBSE (un dual encoder indipendente dalla lingua) e si costruisce la matrice delle similarità coseno

$$S_{ij} = \frac{\langle u_i, v_j \rangle}{\|u_i\| \, \|v_j\|}.$$

Conferma della pagina: la coppia si tiene se il maggiore fra la media dei massimi per riga e per colonna di S è almeno τ_{page}.
Allineamento: una programmazione dinamica monotona su S con mosse 1–1, 1–2, 2–1 (guadagno: il coseno medio) e 1–0, 0–1 (penalità 0,5), limitata alla pagina a fronte; un segmento si tiene se il suo coseno medio è almeno τ_{sent}.

- Niente dizionario né `hunalign`: embedding e programmazione dinamica, come in Vecalign.
- Soglie scelte a griglia sull'allineamento manuale di Wdowiak di AS41–42: $(\tau_{\text{page}}, \tau_{\text{sent}}) = (0{,}50;\ 0{,}40)$, F1 0,58.
- Recall 0,54, precisione 0,63: un po' pessimistiche, perché una coppia giusta ma segmentata diversamente conta come errore.

Pulizia del testo allineato

- Gli errori dell'allineatore si riconoscono facilmente, e questo rende il suo output più facile da correggere di quello di `hunalign`.
- Prima si tolgono i residui dell'impaginazione (lo slug di InDesign di AS43, i link "Return to the TOC").
- Dopo pulizia e deduplicazione, dall'archivio digitale della rivista si ricavano 15.465 coppie.

Una coppia si scarta se

1. un lato ha più di 1,6 volte le parole dell'altro;
2. contiene i puntini di un indice;
3. ha due o più caratteri tipici del rumore da OCR;
4. più del 25% delle sue parole inglesi non è in un dizionario.

I dataset

- **Set web**: la nostra prima estrazione (44 numeri), il Good-Sicilian-in-NLLB di Wdowiak e WikiMatrix it–scn.
- **Set curato**: i fogli allineati a mano di Wdowiak, che coprono il 10–20% di un numero, il nostro allineamento di AS19–47 e le pagine di Napizia.
- **Esclusione del test**: si toglie dal training ogni coppia che contiene una frase del test set (794 coppie del set curato).

set	direzione	coppie
web	scn–en	27.386
	it–scn	9.389
curato	scn–en	30.980
	scn–it	10.427
	scn (mono)	14.360
test	scn–en	1.000
	it–scn	1.000

I dati siciliani

- Perché il siciliano di NLLB è rumoroso
- Lo standard letterario
- La normalizzazione e il suo effetto

Lo standard di Cipolla, esteso da Wdowiak per la traduzione automatica.

Perché il siciliano di NLLB è rumoroso

- Circa un terzo del siciliano raccolto da NLLB è dialetto locale, una parte è corso, e poche frasi hanno una traduzione valida.
- Gli encoder multilingue raggruppano i testi per forma superficiale (Verma et al., 2026): cercando il lato *siciliano* di una frase inglese si trova testo con la grafia dei dati iniziali, e un testo che sembra corso passa per siciliano.
- La stessa vicinanza all'italiano permette al nostro allineatore di funzionare su una lingua che LaBSE non supporta ufficialmente.

LaBSE su FLORES-200 devtest:

recupero scn→en P@1	99%
italiano (supportato)	100%
lingua più vicina dopo l'inglese	italiano
49%, francese 21%	

Più il testo è standard, meglio si allinea:

	coseno	$\geq \tau_{\text{sent}}$
prosa standard	0,76	91%
poesia dialettale	0,64	80%

Standardizzare il siciliano

- Non esiste un'ortografia ufficiale unica, ma uno standard letterario dà da secoli una coerenza di massima, e la maggior parte del siciliano di NLLB lo segue.
- Normalizziamo verso lo standard di Cipolla, esteso da Wdowiak per la traduzione: L sugli articoli (*lu/la/li*), H su *aviri* (*haiu, havi, hannu*), CI per *ci*, R mantenuta prima di un clitico (*farlu*).

Regole di grafia (livello "std"):

cchiù	→	chiù
io / iu / eu	→	jo
non	→	nun
'un, 'unn	→	nun
pri / pir	→	pi

Il livello "full" scioglie anche le contrazioni e toglie gli accenti.

Normalizzazione: sciogliere le contrazioni, e quanto rende

Sciogliere preposizione + articolo:

ô	→	a lu	dû	→	di lu
câ	→	cu la	ntô	→	nta lu

Prima: `ntô libbru dû nannu`
Dopo: `nta lu libbru di lu nannu`

Il tokenizer Napizia, reimplementato in Python; il suo output coincide con quello del codice Perl.

Effetto su NLLB (scn→en, BLEU / chrF):

	BLEU	chrF
grezzo	30,67	56,31
std	**30,79**	**56,49**
full	30,61	56,36

"std" vince di appena 0,1 BLEU, entro il rumore; "full" non fa meglio del testo grezzo, come ci si aspetta da un tokenizer addestrato su testo non normalizzato.

- L'obiettivo di addestramento
- Il Transformer e l'attenzione
- Segmentazione in sottoparole (BPE)
- La ricetta per pochi dati

Traduzione neurale: la baseline

Vaswani et al., *Attention Is All You Need*.
Sennrich et al., *Neural MT of Rare Words with Subword Units*.
Sennrich & Zhang, *Revisiting Low-Resource NMT*.

L'obiettivo di addestramento

La traduzione neurale è un modello linguistico condizionato: un encoder legge la sorgente $x = (x_1, \ldots, x_n)$ e un decoder scompone la probabilità della frase d'arrivo token per token, da sinistra a destra,

$$p_\theta(y \mid x) = \prod_{t=1}^{|y|} p_\theta(y_t \mid y_{<t},\, x),$$

e si addestra massimizzando la log-likelihood del corpus parallelo $\mathcal{D}$,

$$\mathcal{L}(\theta) = \sum_{(x,y)\in\mathcal{D}} \sum_{t} \log p_\theta(y_t \mid y_{<t}, x),$$

mentre in decodifica si cerca $\arg\max_y p_\theta(y \mid x)$ con la beam search.

- Il Transformer, le sottoparole e NLLB sono modi diversi di realizzare la stessa p_θ.

Il Transformer

Niente ricorrenza: i token interagiscono attraverso la *scaled dot-product attention*. Con query Q, chiavi K e valori V,

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\Big(\frac{QK^\top}{\sqrt{d_k}}\Big)V,$$

calcolata da più teste (*head*) in parallelo,

$$\mathrm{MultiHead} = \mathrm{Concat}(\mathrm{head}_1, \dots, \mathrm{head}_h)\, W^O,$$

$\mathrm{head}_i = \mathrm{Attention}(QW_i^Q, KW_i^K, VW_i^V)$. Ogni strato aggiunge una rete feed-forward applicata a ogni posizione, connessioni residue e layer normalization.

- Self-attention nell'encoder e nel decoder; la cross-attention permette al decoder di guardare la sorgente.
- La baseline di Wdowiak e NLLB sono entrambi Transformer encoder–decoder; differiscono per dimensione e per preaddestramento.

Segmentazione in sottoparole: BPE

Le parole rare e flesse si dividono in sottoparole, il che dà un vocabolario aperto e condivide le statistiche fra le forme di una parola. Byte-Pair Encoding:

1. si parte dai caratteri e si contano le coppie di simboli adiacenti;
2. si fonde la coppia più frequente in un nuovo simbolo, e si ripete V volte.

$$(a,b)^\star = \arg\max_{(a,b)} \ \mathrm{count}(a,b) \quad \Longrightarrow \quad \text{nuovo token } ab.$$

- La flessione del siciliano moltiplica le forme delle parole; le sottoparole riducono la sparsità.
- L'esempio di Wdowiak: *Carinisi are dogs!* diventa `car@@ in@@ isi are dogs !`

La ricetta per pochi dati

Con pochi dati il Transformer standard va in overfitting. Sennrich & Zhang (2019) prescrivono un modello più piccolo e fortemente regolarizzato:

- meno strati, e più stretti, e un vocabolario BPE piccolo;
- dropout alto e label smoothing.

La nostra baseline usa Sockeye-3 con queste dimensioni, su CPU.

	default	nostra
strati	6	3
dimensione	512	256
teste	8	4
feed-forward	2048	1024

circa 6,7M parametri; dropout 0,4 sugli embedding, 0,2 altrove; BPE congiunto da 4.000 fusioni.

Leve linguistiche

Leva B: sottoparole orientate alle desinenze

- Il tokenizer toglie gli accenti e scioglie le contrazioni; il BPE congiunto è orientato alle desinenze dei manuali (Dieli, Cipolla, Bonner, *Chiù dâ Palora*), aggiunte al lato siciliano quando si imparano le fusioni.
- Baseline Sockeye 8,51 → 10,94 BLEU.

Leva D: il lemma come fattore della sorgente

- Un embedding del lemma si somma all'embedding della sorgente (Sennrich & Haddow, 2016),

$$e_j = E_{\text{word}}(w_j) + E_{\text{lemma}}(\ell_j),$$

  con la tabella dei lemmi del sistema originale (16.377 forme, 1.252 lemmi).
- Abbassa il punteggio a 10,18 BLEU.

Entrambe restano molto sotto il modello preaddestrato della prossima sezione, che arriva a 29,00 BLEU senza alcun adattamento.

- NLLB-200
- Fine-tuning efficiente: LoRA
- Adapter bidirezionale e back-translation
- L'italiano come lingua ponte

Un modello multilingue preaddestrato, adattato

NLLB Team, *No Language Left Behind*.
Hu et al., *LoRA*. Sennrich et al., *Back-translation*.
Johnson et al., *Multilingual NMT*. Fan et al., *Beyond English-Centric*.

NLLB-200: un Transformer massivamente multilingue

Un encoder–decoder addestrato su 200 lingue, fra cui il siciliano (`scn_Latn`). La lingua d'arrivo si sceglie forzando il primo token del decoder,

$$p_\theta(y \mid x, \ell_{\text{tgt}}), \qquad y_0 = \langle \texttt{scn_Latn} \rangle \; o \; \langle \texttt{eng_Latn} \rangle.$$

Senza adattamento traduce il siciliano letterario in inglese a 29,00 BLEU, contro 10,94 del miglior modello addestrato da zero.

- Usiamo la variante da 1,3B.
- Il trasferimento da 200 lingue è ciò che manca al modello piccolo.
- Il problema è come adattare 1,3 miliardi di parametri a circa 30.000 coppie su una sola GPU.

Fine-tuning efficiente: LoRA

Si congelano i pesi preaddestrati $W_0 \in \mathbb{R}^{d\times k}$ e si impara un aggiornamento di rango basso (Hu et al., 2021):

$$W = W_0 + \frac{\alpha}{r} BA, \qquad B \in \mathbb{R}^{d\times r},\ A \in \mathbb{R}^{r\times k},$$

con $r \ll \min(d, k)$; il forward pass diventa

$$h = W_0\, x \ + \ \tfrac{\alpha}{r}\, B(Ax).$$

- Sulle proiezioni di query, chiave, valore e output, r=32, α=64: 18,9M parametri addestrabili, l'1,4% del modello.
- Base in fp16, adapter in fp32; una GPU di Colab.
- Per l'inferenza l'adapter si può incorporare in W_0.

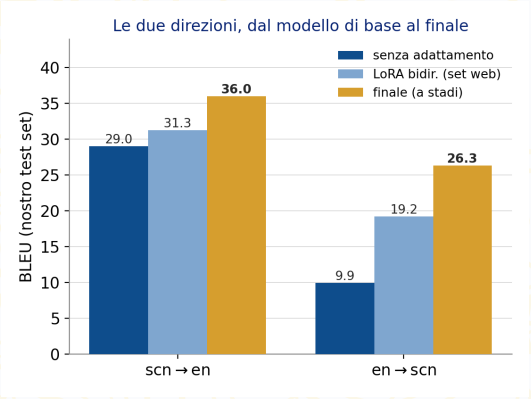
Un adapter per le due direzioni

Invece di un modello per direzione, un solo adapter si addestra sull'unione

$$\mathcal{D}_{\leftrightarrow} = \{(x^{\text{scn}}, y^{\text{en}})\} \cup \{(x^{\text{en}}, y^{\text{scn}})\},$$

ogni esempio con il token della sua lingua d'arrivo forzato.

- Sul set web: scn→en 29,00 → 31,27, en→scn 9,90 → 19,19 BLEU.
- Il modello finale a stadi arriva a 36,01 e 26,34 (sezione successiva).



Back-translation e italiano come ponte

Back-translation (Sennrich et al., 2016): con un modello inverso $M_{t \to s}$ e testo monolingue nella lingua d'arrivo,

$$x' = M_{t \to s}(y), \qquad \mathcal{D}^+ = \mathcal{D} \cup \{(x', y)\};$$

il lato d'arrivo è reale, solo la sorgente è sintetica.

Dalle 7.592 frasi inglesi rimaste senza allineamento: 7.498 coppie, scn→en 31,27 → 31,60. Il testo dello stesso dominio è poco; l'addestramento a stadi usa invece circa un milione di back-translation.

L'italiano come ponte (Johnson et al., 2017; Fan et al., 2020): l'italiano è vicino al siciliano e ha molti più dati. Un adapter trilingue su scn↔en e it↔scn dà scn→it 43,47 e it→scn 17,57 → 26,97,

ma un po' meno su scn↔en (30,75 / 17,49 contro 31,27 / 19,19): sul set web il ponte non aiuta le direzioni con l'inglese.

Addestramento a stadi

- La ricetta del reverse training, su NLLB
- Back-translation con il punteggio del modello diretto
- Lo stadio di sgrossatura
- Studio di ablazione

Wdowiak, *A Reverse Training Strategy for Sicilian NMT*.

Dal reverse training a NLLB a stadi

La ricetta di Wdowiak: un modello it–en bidirezionale su ParaCrawl, poi le sue traduzioni in siciliano, poi le retrotraduzioni del siciliano di NLLB, poi *Arba Sicula*.

La nostra: NLLB fornisce già il preaddestramento multilingue, quindi restano solo gli ultimi due stadi.

1. back-translation (6 liste, 4 direzioni) e 100.000 coppie it–en naturali, un'epoca;
2. il set curato, scn↔en e scn↔it, due epoche.

Punteggio del modello diretto: ogni coppia sintetica riceve la log-probabilità negativa che il suo lato siciliano reale traduca quello sintetico, secondo i modelli di Wdowiak addestrati sullo standard letterario; il siciliano standard di solito ha un punteggio più basso del dialetto.

Le 100.000 coppie migliori per lista, dopo alcuni filtri: almeno 5 parole, niente quasi-copie, nessuna sovrapposizione col test, e poche parole in -o (l'italiano che passa per siciliano ottiene i punteggi migliori).

Addestramento a stadi: risultati sul nostro test set

modello	scn→en	en→scn
LoRA bidir. (web)	31,27	19,19
a stadi	32,40	21,72
con sgrossatura iniziale	33,01	21,78

Il guadagno è maggiore verso il siciliano (+2,53) che dal siciliano (+1,13), forse perché le back-translation sono state scelte per la qualità del lato siciliano. Il confronto mescola due cambiamenti (set curato e retrotraduzioni).

Lo stadio di sgrossatura (proposta di Wdowiak): un'epoca sulle 200.000 coppie con il punteggio *peggiore* per lista, cioè sul testo dialettale, italiano e corso, distribuisce le probabilità d'uscita fra i dialetti; gli stadi successivi le concentrano.

Aiuta dal siciliano (+0,61) ma non verso il siciliano. Però aggiunge anche un'epoca, quindi non è certo da dove venga il guadagno.

Studio di ablazione: che cosa limita il modello a stadi

	base	+ 300k	+ rango 64	+ 3 modifiche	finale
nostro test (BLEU)					
scn→en	32,82	33,34	34,60	35,40	**36,01**
en→scn	21,52	21,88	24,18	25,09	**26,34**
test di Wdowiak (BLEU, spazio tokenizzato)					
en→scn	44,42	44,49	47,64	48,36	**49,25**
scn→en	57,14	58,54	62,02	60,95	59,34

- Le tre modifiche: 300.000 coppie per lista nel secondo stadio, un adapter di rango 64 anche sugli strati feed-forward, sequenze da 256 token e una terza epoca. La maggior parte del guadagno viene dall'adapter.
- Finale: le coppie it–scn di WikiMatrix nel terzo stadio e fino a quattro epoche, scelto sul validation set, dove è il migliore fra tutte le varianti.

Risultati

- Valutazione: BLEU, chrF e lo spazio tokenizzato
- Il nostro test set
- Il forgetting nelle direzioni non addestrate
- Il test set di Wdowiak e la baseline riaddestrata

Papineni et al., *BLEU*. Popović, *chrF*. Post, *sacreBLEU*.

Valutazione

BLEU: precisione modificata degli n-grammi, con una penalità di brevità,

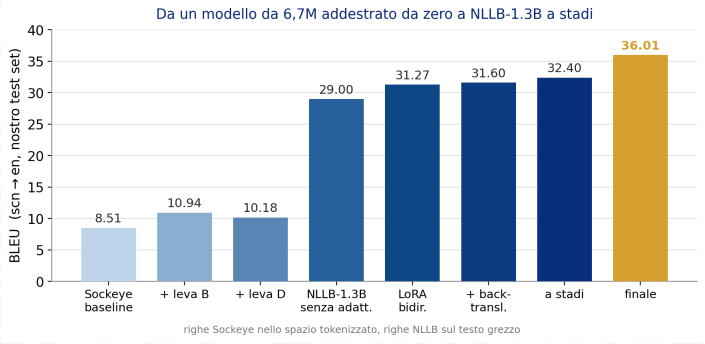
$$\mathrm{BLEU} = \min(1, e^{1-r/c}) \cdot \exp\Big(\sum_{n=1}^{4} w_n \log p_n \Big).$$

chrF: l'F-score degli n-grammi di caratteri, più adatto alle lingue morfologicamente ricche,

$$\mathrm{chrF}_\beta = (1+\beta^2)\, \frac{\mathrm{chrP} \cdot \mathrm{chrR}}{\beta^2\, \mathrm{chrP} + \mathrm{chrR}}.$$

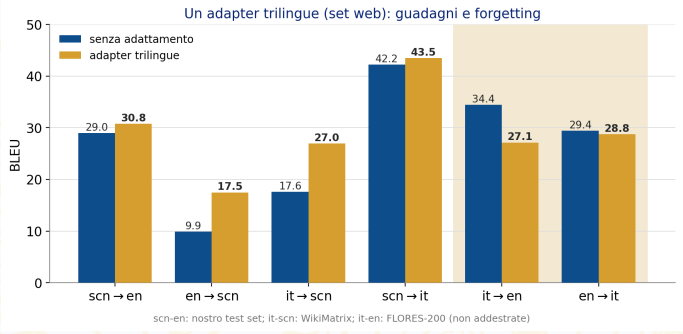
- sacreBLEU (13a) sul nostro test set fisso di 1.000 coppie letterarie; non FLORES, il cui siciliano segue l'ortografia introdotta dopo il 2017 ed è di un altro dominio.
- Test set di Wdowiak: 121 righe trilingui, valutate come faceva lui nello spazio del tokenizer Napizia (accenti tolti, contrazioni sciolte).
- Quello spazio è più indulgente verso il siciliano: en→scn 21,72 → 25,69, scn→en 32,37 → 33,03.

Il nostro test set (scn→en)



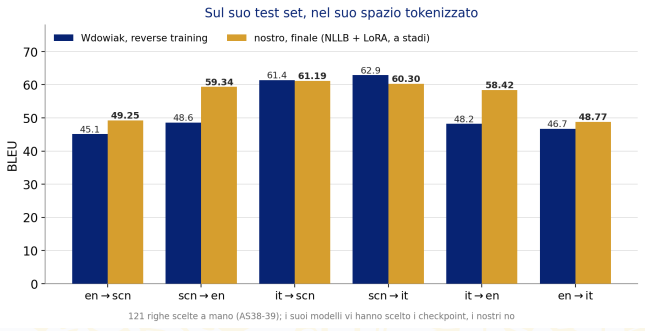
- La baseline Sockeye supera di 3,3 BLEU il punteggio della sorgente lasciata non tradotta (8,51 contro 5,18).
- NLLB senza adattamento supera di 18 BLEU il miglior modello addestrato da zero.
- L'addestramento a stadi e l'ablazione lo portano a 36,01 (26,34 verso il siciliano).

Il forgetting nelle direzioni non addestrate



- L'adapter trilingue abbassa it→en da 34,42 a 27,14 BLEU su FLORES-200, una direzione su cui non è mai stato addestrato.
- Questo ne limita l'uso come modello multilingue generale; probabilmente ne risentono anche le direzioni fra siciliano e spagnolo, francese o portoghese.

Il confronto con i sistemi pubblicati



- Modello finale contro il reverse training di Wdowiak: +4,2 BLEU verso il siciliano, +10,7 dal siciliano, e sopra anche fra inglese e italiano.
- Sotto fra siciliano e italiano (61,19 contro 61,4, 60,30 contro 62,9).
- Non del tutto alla pari: i suoi sistemi hanno scelto i checkpoint su queste righe, i nostri si addestrano per un numero fisso di epoche.

Quindi il punteggio basso en→scn sul nostro test set dipende probabilmente dal test set e dalla metrica più che dal modello.

La baseline originale, riaddestrata

training set	coppie	en→scn	scn→en
pubblicata	–	25,1	29,1
A (suoi fogli)	20.220	15,97	16,65
B (nostro allin.)	18.503	13,20	13,14
C (entrambi)	31.730	22,45	20,69

Suo test set, suo spazio tokenizzato, BLEU.

- La sua configurazione del 2022 (tokenizzazione Napizia, BPE separati da 3.000 fusioni, 3 strati da 256), con Sockeye 3 invece di Sockeye 1.
- Sui suoi dati resta molto sotto i punteggi pubblicati: lui partiva da un modello precedente e si fermava sul test set; nessuno dei nostri addestramenti è arrivato a convergenza in 20 epoche.
- Il nostro allineamento aggiunto ai suoi fogli la alza di 4,0–6,5 BLEU: l'allineamento automatico porta coppie che quello manuale non contiene.

Conclusioni e prospettive

- Il percorso dai PDF di *Arba Sicula* a un sistema siciliano–inglese è stato ricostruito con software ancora mantenuto: estrazione, allineamento e pulizia, il tokenizer portato in Python, e NLLB-200 con LoRA addestrato a stadi.
- Sul nostro test set il modello finale arriva a 36,01 BLEU (scn→en) e 26,34 (en→scn); su quello di Wdowiak supera il suo reverse training nelle direzioni con l'inglese e resta sotto fra siciliano e italiano.
- Il modello gira anche sulla CPU: convertito in CTranslate2 con pesi int8 occupa 1,4 GB su disco e 2,5 GB di memoria, circa 3 s per frase con 2 thread, e perde meno di 0,5 BLEU.
- Prossimi passi: limitare il forgetting con un corpus multi-parallelo, e la stessa pipeline per il calabrese, il salentino e le altre varietà d'Italia (LaBSE ne recupera la traduzione inglese nel 98,5–99,9% dei casi su FLORES-200).

Articolo: arXiv:2610.30374. Codice: `github.com/dmeoli/SicilianNMT`.

Ringraziamenti

- **Arba Sicula**, **Gaetano Cipolla** e **Arthur Dieli**, per la rivista bilingue, il vocabolario e la grammatica, e per il permesso di usarne le collezioni digitali.
- **Eryk Wdowiak**, coautore dell'articolo: questo lavoro si basa sul suo *Tradutturi Sicilianu*, sui suoi fogli allineati a mano e sulle sue back-translation.
- I progetti open source che usa: PyMuPDF, LaBSE e sentence-transformers, Sockeye, NLLB-200, PEFT, sacreBLEU, CTranslate2.

Grazzii assai.

Grazzii *p'a vostra attenzioni*!